

Analiza zmienności wybranych
wskaźników klimatycznych w latach
1995–2024 na obszarze masywu
górskiego Serra da Estrela oraz w
przyległych regionach wschodniej
Portugalii i zachodniej Hiszpanii.

Marta Haratyk

05.01.2026

Spis treści

1	Wstęp	2
2	Dane	2
2.1	Źródło danych	2
2.2	Zakres przestrzenny i czasowy	2
2.3	Wstępny opis pobranych danych	2
3	Analiza	3
3.1	Statystyki opisowe	3
3.2	Porównania dla różnych sezonów i obszarów	4
3.3	Podział obszaru	5
3.4	Trend i sezonowość	6
3.5	Zależności między zmiennymi	9
3.6	Analiza anomalii	13
4	Wnioski	13
4.1	Najważniejsze obserwacje	13
4.2	Ograniczenia danych	14
5	Przewidywanie	14
5.1	Model ML	14
6	Bibliografia	14

1 Wstęp

Celem analizy jest ocena zmian klimatu w wybranym obszarze północno-wschodniej Portugalii, poprzez deskryptywną i diagnostyczną analizę danych ERA5. Analiza obejmuje średnie, ekstremalne wartości oraz sezonowość kluczowych zmiennych klimatycznych. Główne pytanie badawcze brzmi: „Jak zmienia się klimat w północno-wschodniej Portugalii w ostatnich dekadach?”. W tej analizie szczególną uwagę poświęcono badaniu zmian temperatury i wilgotności gleby oraz potencjalnemu wystąpieniu suszy.

2 Dane

2.1 Źródło danych

Do analizy wykorzystano dane pochodzące z reanalizy klimatycznej ERA5. Dane pobrano w postaci kilku plików (zwykle obejmujących 2–3 lata), które następnie zostały połączone w jeden plik w formacie NetCDF.

Dodatkowe modyfikacje danych obejmują:

- ujednolicenie nazewnictwa zmiennych,
- korektę zapisu długości geograficznej (zmiana z zakresu 0° – 360° na -180° – 180°),
- poprawne ustawienie kierunku danych (punkt początkowy – północny-zachód, punkt końcowy – południowy-wschód),
- reorganizację zmiennej czasowej (czas w pliku był rozbity na dwa parametry: `time`, informujący o czasie pomiaru, oraz `step`, wskazujący przesunięcie względem czasu bazowego; parametry te zostały połączone, tworząc spójny szereg czasowy).

2.2 Zakres przestrzenny i czasowy

Obszar analizy obejmuje fragment Serra da Estrela i okolice, ograniczony geograficznie od 39.65°N do 41.4°N oraz od 7.75°W do 7.0°W .



Rysunek 1: Ilustracja pokazująca przybliżony obszar analizy

Dane znajdują się w przedziale czasowym od 01.01.1995 do 31.12.2024. Zbiór zawiera pomiary z wszystkich lat, miesięcy oraz dni zawartych w tym przedziale, dla godzin: 00:00, 6:00, 12:00, 18:00.

2.3 Wstępny opis pobranych danych

Zbiór nie zawiera braków, ani wartości odstających (outlierów).

Pobrane zmienne możemy podzielić ze względu na rodzaj ich zapisu:

- **dane chwilowe:** odczyt konkretnej wartości w danej chwili,

- **dane akumulowane:** wartości sumują się od momentu rozpoczęcia kroku czasowego.

Tabela 1: Charakterystyka zmiennych meteorologicznych w pobranych danych

Zmienna	Opis	Jednostka
<i>Dane chwilowe</i>		
t2m	Temperatura powietrza na wysokości 2 m	°C
d2m	Temperatura punktu rosy na wysokości 2 m	°C
swvl1	Wilgotność gleby (0–7 cm)	m ³ m ⁻³
swvl2	Wilgotność gleby (7–28 cm)	m ³ m ⁻³
swvl3	Wilgotność gleby (28–100 cm)	m ³ m ⁻³
swvl4	Wilgotność gleby (100–289 cm)	m ³ m ⁻³
cape	Konwekcyjna dostępna energia potencjalna (sprzyjająca gwałtownym zjawiskom)	J kg ⁻¹
wind_speed	Prędkość wiatru na 10 m	m s ⁻¹
wind_dir	Kierunek wiatru na 10 m	°
<i>Dane akumulowane</i>		
tp	Całkowity opad atmosferyczny	mm
sf	Opad śniegu (ekwiwalent wody)	mm
e	Parowanie powierzchniowe	mm
ssrd	Promieniowanie słoneczne krótkofalowe	MJ m ⁻²

3 Analiza

3.1 Statystyki opisowe

	mean	std	min	p25	median	p75	max
swvl1	0.265	0.105	0.069	0.157	0.282	0.36	0.441
swvl2	0.277	0.087	0.127	0.187	0.279	0.357	0.44
swvl3	0.287	0.067	0.134	0.229	0.274	0.345	0.438
swvl4	0.318	0.038	0.217	0.292	0.316	0.343	0.428
cape	27.746	118.474	0.0	0.0	0.0	4.574	5183.25
t2m	14.229	7.554	-9.899	8.747	13.259	18.921	41.692
d2m	7.786	4.813	-18.838	4.602	8.193	11.447	21.55
sf	0.0	0.017	0.0	0.0	0.0	0.0	4.139
ssrd	0.665	1.021	-0.0	0.0	0.029	1.108	3.595
e	-0.071	0.103	-0.633	-0.121	-0.011	-0.002	0.089
tp	0.086	0.349	0.0	0.0	0.0	0.006	19.572
wind_speed	2.507	1.364	0.002	1.53	2.205	3.272	11.56
wind_dir	189.43	109.163	0.0	74.265	216.163	284.156	360.0


Rysunek 2: Podstawowe statystyki opisowe dla danych zaagregowanych w przestrzeni i czasie

Tabela zawiera informacje o podstawowych statystykach. Warto zwrócić uwagę na:

- zachowanie poszczególnych warstw wilgotności gleby- im głębiej położona warstwa tym mniejsza jest jej zmienność oraz wyższa wartość (niższe warstwy są bardziej wilgotne i nie ulegają tak szybkim zmianom, dlatego są istotnym wskaźnikiem w badaniu suszy),
- zmienna cape w większości przypadków przyjmuje wartość 0, wynika to ze sposobu pozyskania danych — była rejestrowana jako wartość chwilowa jedynie dla czterech wybranych godzin w ciągu doby, a przez znaczną część czasu wskaźnik ten naturalnie pozostaje równy 0,
- bardzo niskie wartości dla opadów- wynika to również ze sposobu zapisu- dane dot. opadów są akumulowane dla kroku (np. dla kroku godzinowego są to dane z ostatniej godziny), dlatego wartości są bliskie 0,
- niskie prędkości wiatrów- wiatr jest zmienną mierzoną w konkretnej chwili, dlatego prawdopodobnie w pomiarach nie znalazły się najsilniejsze porywy,

- kierunek wiatru- badany obszar jest głównie nawiewany od strony Oceanu Atlantyckiego.

Wykonano również wykresy typu boxplot oraz histogramy, które pokazują wcześniej opisane cechy zmiennych oraz informują że żadna ze zmiennych nie ma rozkładu normalnego.




Rysunek 3: Wykresy boxplot

3.2 Porównania dla różnych sezonów i obszarów

Wykonano przestrzenną analizę średnich, liczonych dla okresu 5 lat, dla każdego z obszarów mapy.


W każdym przypadku zaobserwowano różne zmiany na przestrzeni lat, jednak dla poniższych zmiennych były one szczególnie wyraźne:

CAPE – widoczny jest wyraźny wzrost tego wskaźnika w ostatnich latach, szczególnie w północno-zachodniej części obszaru. Po wykonaniu dodatkowej analizy ekstremów dla poszczególnych lat zauważono, że na wzrost czynnika mogły wpłynąć bardzo burzowe lata 2018 i 2022. W 2018 roku na badanym obszarze, jak i w całej Portugalii, występowały anomalie w cyrkulacji atmosferycznej, powodujące gwałtowne burze w czerwcu i lipcu. Z kolei w 2022 roku nad Portugalię i Hiszpanię napłynęło gorące powietrze z Sahary, które znacząco podniosło temperaturę, a następnie resztki systemów tropikalnych, podnoszących wilgotność, co ostatecznie doprowadziło do rekordowo wysokich wskaźników CAPE. Wykonano wizualizację mediany, która również pokazała znaczący wzrost zmiennej w tym obszarze.




Rysunek 4: Analiza zmiany wartości średniej liczonej dla CAPE

d2m – zmienna informująca o temperaturze punktu rosy w ostatnich latach wróciła do wartości podobnych lub nawet wyższych niż w latach 1995–2005. Te same zależności odczytano z wykresu ekstremów dla kolejnych lat oraz z wykresu przedstawiającego medianę.




Rysunek 5: Analiza zmiany wartości średniej liczonej dla d2m

swvl – wszystkie poziomy wilgotności gleby odnotowały spadki w ostatnich latach, jednak najlepiej przedstawia to wizualizacja dla warstwy 4 (najgłębszej). Zjawisko to jest szczególnie obserwowane w południowej części obszaru.



Rysunek 6: Analiza zmiany wartości średniej liczonej dla swvl4

t2m – odnotowano wzrosty temperatury w ostatnich latach, szczególnie w rejonach południowych. Analiza rozkładu ekstremów temperatury w kolejnych latach wskazuje na wysokie wartości w roku 2022, związane z wcześniej wspomnianą falą upałów.




Rysunek 7: Analiza zmiany wartości średniej liczonej dla t2m

Zauważono również spadek ilości opadów deszczu, zanik opadów śniegu, które występowały w północnej części obszaru, oraz drobne zmiany w kierunku wiatru.

3.3 Podział obszaru

Na podstawie przedstawionych wizualizacji oraz mapy ukształtowania analizowanego terenu wyróżniono trzy podobszary. Do podziału zastosowano algorytm k-średnich z ustaloną z góry liczbą klastrów (3).



Opis klastrow:

- **Klaster 0** – obszar górski, obejmuje masyw Serra da Estrela oraz obszar na północy – pasmo Serra do Gerês. Obydwie krainy geograficzne charakteryzują się niższymi temperaturami i możliwością występowania opadów śniegu.
- **Klaster 1** – część wyżynna analizowanego obszaru, nazywana Terra Fria (kraina zimna). Obszar ten pozostaje pod wpływem klimatu kontynentalnego – zimne zimy oraz ciepłe, suche lata.
- **Klaster 2** – doliny rzeczne, otoczone przez góry, o klimacie śródziemnomorskim, charakteryzującym się gorącym latem i dużym nasłonecznieniem.


3.4 Trend i sezonowość

Dane w zależności od badanego podobszaru oraz pory roku zostały zbadane pod kątem występowania trendu i jego istotności statystycznej. Zastosowano zmodyfikowany test statystyczny Mann-Kendall (TFPW-MK), pozwalający na sprawdzenie istotności trendu dla danych, których rozkład nie jest normalny, uwzględnia on również możliwość występowania autokorelacji w danych (na podstawie wykresów acf i pacf można zauważyć że autokorelacja występuje w danych).

Większość z obecnych trendów okazała się nie być istotna statystycznie. Odkryto jednak kilka istotnych wzorców.


e – istotny trend pojawił się dla klastra 3 w sezonie letnim i jesiennym. Jako, że zmienna przyjmuje wartości ujemne trend rosnący w tym przypadku oznacza, że coraz mniejsze ilości wody wyparowują z powierzchni.

Trendy Sezonowe z korektą autokorelacji (TFPW-MK): e




sf- wykryto istotny spadek dla klastra 0, gdzie opady śniegu były normą, jednak z czasem zaczęły zanikać. Na wykresie obserwujemy też dużą ilość opadów koło roku 2010, a następnie brak opadów w kolejnych latach.

Trendy Sezonowe z korektą autokorelacji (TFPW-MK): sf




swvl - zmiany w wilgotności gleby na głębokim poziomie są znaczne. wilgotność na 3 poziomie we wszystkich podobszarach utrzymuje w sezonie letnim i zimowym tendencję malejącą, najszybciej maleje dla klastra 3 w lecie. Dla najgłębszego poziomu 4 zmiany zachodzą tylko dla klastra 3 (we wszystkich porach roku) oraz dla klastra 2 (tylko w zimie).

Trendy Sezonowe z korektą autokorelacji (TFPW-MK): swvl3



Trendy Sezonowe z korektą autokorelacji (TFPW-MK): swvl4




t2m - odnotowano istotny wzrost temperatury, nachylenie dla wszystkich lini trendu przekracza 0,04. Najszybciej temperatury rosną dla klastra 1, prawie 0,5 stopnia rocznie. Istotność w sezonie jesiennym wynika prawdopodobnie z najbardziej stabilnych temperatur właśnie w tym sezonie. Gwałtowny wzrost przypadający na ten sezon pokazuje na przesuwanie się letnich warunków klimatycznych w kierunku wczesnych miesięcy jesieni. Wpływ na to mogą mieć też coraz mniej srogie zimy.

Trendy Sezonowe z korektą autokorelacji (TFPW-MK): t2m



wind_dir- wykres obrazuje istotną zmianę kierunku wiatru w lecie. Więcej wiatrów przychodzi z północy, czyli z części kontynentalnej, nie z południa, czyli z części atlantyckiej. Wiatry kontynentalne mogą przynosić suche i ciepłe powietrze w przeciwieństwie do wilgotnych podmuchów atlantyckich.

Trendy Sezonowe z korektą autokorelacji (TFPW-MK): wind_dir



3.5 Zależności między zmiennymi

Wykonano macierze przedstawiające wartości współczynników korelacji Spearmana dla zmiennych.


Macierz wartości współczynnika korelacji Spearmana między zmiennymi w latach (1995-2024): Klaster 0



Macierz wartości współczynnika korelacji Spearmana między zmiennymi w latach (1995-2024): Klaster 0



Macierz wartości współczynnika korelacji Spearmana między zmiennymi w latach (1995-2024): Klaster 2



Rysunek 8: Zestawienie wartości współczynnika korelacji dla podobszarów

Korelacje dla wszystkich klastrow są podobne. Niewielkie różnice obserwujemy np. dla zależności od opadów śniegu (z racji na brak opadów dla klastra 2 wartości współczynników dla tej zmiennej są bliskie 0). W klastrze drugim z reguły zależności są niższe np. pomiędzy pomiarem temperatury i temperatury punktu rosy.

Głównie zależności obserwujemy między:

- Zależności pomiędzy warstwami wilgotności gleby:

- Wysoki współczynnik korelacji między kolejnymi warstwami swvl1, swvl2 i swvl3 pokazuje, że są od siebie zależne. Najgłębsza warstwa swvl4 jest znacząco zależna jedynie od warstwy poprzedzającej. Głębsze warstwy są bardziej stabilne, dlatego stanowią dobry wskaźnik do oceny osuszania terenu oraz ryzyka wystąpienia suszy.
- Wilgotność w głębszych warstwach jest szczególnie istotna dla roślin o głębokim systemie korzeniowym, np. winorośli, uprawianych na badanym obszarze. Obniżanie się wartości swvl3 i swvl4 wskazuje na utrzymujący się deficyt wody trwający kilka miesięcy. Te zmienne nie są też skorelowane z opadami tak jak warstwy powierzchniowe (swvl1 i swvl2).


- Korelacje z temperaturą:

- Trzy górne warstwy wykazują wysoką korelację ujemną z temperaturą powietrza (t2m) oraz temperaturą punktu rosy (d2m), co oznacza, że wzrost temperatury prowadzi do spadku wilgotności gleby.
- Temperatura powietrza i temperatura punktu rosy są ze sobą skorelowane, przy czym t2m wykazuje również silny związek z parowaniem gruntów (zmienna 'e'). Jednak najsilniejszy wpływ na parowanie ma nasłonecznienie (ssrd).


- Zauważalne są również zależności odwrotne między parowaniem a prędkością wiatru oraz dodatnia korelacja między temperaturą punktu rosy a konwekcją.

Dla niektórych zależności wykonano wykresy rozrzutu.


cape vs d2m- wyraźna zależność pomiędzy zmiennymi. Z wykresu można odczytać także, że najwyższe wartości konwekcji odnotowano dla klastra 0.




ssrd vs e- korelacja między zmiennymi jest znacząca, najbardziej widoczna dla klastra 0. Ponadto na wizualizacji obserwujemy grupowanie się punktów w skupiska wraz z rosnącym nasłonecznieniem. Prawdopodobnie jest to wynikiem silnej sezonowości tej zmiennej.



tp vs swvl3- z wykresu odczytano pewną zależność jednak nie jest ona silna. Punkty są najsilniej skupione w dolnym, lewym rogu wykresu, gdzie zarówno wartości dla opadów jak i dla wilgotności są niskie. Wraz ze wzrostem wartości punkty stają się coraz bardziej rozproszone.




t2m vs d2m- najsilniejsze powiązanie dla klastra 0 (wynika z topografii tego klastra- jego klimat sprzyja tej zależności).



3.6 Analiza anomalii

Poniższe wykresy przedstawiają liczbę dni ekstremalnych w poszczególnych klastrach. Za dni ekstremalne uznano te przypadki, w których w obrębie danego sezonu wartości wilgotności gleby na poziomach swvl3 i swvl4 były niższe niż pierwszy kwartyl (0,25), a jednocześnie temperatura powietrza przekraczała trzeci kwartył (0,75).

We wszystkich klastrach najsilniejszy trend wzrostowy liczby dni ekstremalnych odnotowano w sezonie jesiennym. W ostatnich latach obserwuje się nie tylko wzrost częstości występowania tych zjawisk, ale także ich wysoką powtarzalność z roku na rok. Stanowi to zmianę w stosunku do lat wcześniejszych, gdy ekstrema nie były normą, a okresy anomalii przeplatały się z latami, w których ich liczba była bliska zero. Zauważalne grupowanie się lat o podwyższonych wskaźnikach (tzw. klastrowanie w czasie) wynika z dużej inercji i "pamięci" procesów hydrologicznych, w szczególności wilgotności gleby w głębszych warstwach.



Rysunek 9: Zestawienie ilości dni ekstremalnych dla podobszarów

4 Wnioski

4.1 Najważniejsze obserwacje

Analizowane dane charakteryzują się znaczną zmiennością czasową. Zmienność ta w większości przypadków wynika z oddziaływania czynników zewnętrznych, takich jak nietypowe napływy ciepłych mas powietrza. Dla wielu zmiennych zaobserwowano okresowe fluktuacje oraz powroty do wartości z początku badanego okresu, co utrudniało identyfikację jednoznacznych, trwałych wzorców zmian. Ze względu na klimatyczny charakter danych ich istotną cechą była wyraźna sezonowość, przy czym największe zmiany występowały w sezonach letnim i jesiennym.

Szczególnie wyraźnie odnotowano spadek wilgotności w głębokich warstwach gleby. Zjawisku temu towarzyszył niewielki spadek sum opadów oraz parowania, a także wzrost wartości wskaźnika CAPE. W połączeniu z istotnym wzrostem temperatury powietrza, zwłaszcza w okresie jesiennym, obserwacje te wskazują na zwiększone ryzyko wystąpienia suszy w badanym rejonie. Jest to zjawisko niekorzystne, ponieważ jesień stanowi zazwyczaj okres naturalnej regeneracji i odbudowy zasobów wodnych w glebie; podwyższone temperatury w tym czasie mogą istotnie zaburzać ten proces.

Podczas gdy górne warstwy gleby reagują głównie na krótkotrwałe zmiany warunków pogodowych, stan głębszych warstw umożliwia wnioskowanie o występowaniu suszy o charakterze długotrwałym. Zjawisko to mogło być związane ze zmniejszającymi się sumami opadów oraz zanikiem pokrywy śnieżnej, szczególnie na obszarach wyżynnych i górskich. Wraz z postępującym przesuszaniem gruntu obserwowano również obniżenie parowania, a także wzrost temperatury punktu rosy i intensyfikację procesów konwekcyjnych w ostatnich latach. Warunki te sprzyjają występowaniu wyładowań atmosferycznych, które na przesuszonych obszarach mogą prowadzić do powstawania szczególnie niebezpiecznych pożarów.

Należy również zaznaczyć, że w ostatnich latach występowały liczne anomalie pogodowe, a wiele z analizowanych zmiennych osiągało w tym okresie wartości nietypowe w skali całego badanego przedziału czasowego.

4.2 Ograniczenia danych

Ze względu na sposób pozyskiwania danych, obejmujący jedynie cztery godziny na dobę, część zmiennych charakteryzowała się niepełną reprezentacją warunków dobowych i nie mogła rzetelnie odzwierciedlać rzeczywistej sytuacji w analizowanym okresie. Brak sum dobowych był znaczący w przypadku zmiennych akumulowanych (takich jak całkowity opad atmosferyczny czy opad śniegu).

Taki sposób próbkowania był również niewystarczający do analizy ekstremów. Aby wiarygodnie identyfikować rzeczywiste maksima i minima dla zmiennych takich jak temperatura powietrza czy porywy wiatru, konieczne byłoby wykorzystanie pełnego zestawu dostępnych obserwacji meteorologicznych o wyższej rozdzielczości czasowej.

Należy również uwzględnić ograniczenia danych ERA5, które mają charakter danych reanalizowych. Wartości zmiennych są interpolowane przestrzennie i reprezentują uśrednione warunki w obrębie pojedynczej komórki siatki obliczeniowej, a nie bezpośrednie pomiary punktowe. Uzyskane wyniki należy interpretować jako przybliżenie warunków klimatycznych w badanym obszarze.

5 Przewidywanie

5.1 Model ML

Zgromadzone dane nadają się do wykorzystania w modelach uczenia maszynowego, są dobrej jakości i jest ich wystarczająco dużo, aby skutecznie wytrenować model, należy jednak pamiętać o ich ograniczeniach. W zbiorze występują zależności, które zazwyczaj nie są liniowe (warto rozważyć bardziej złożone algorytmy np. lasy losowe). Ze względu na zróżnicowane rzędy wielkości i jednostki, wiele zmiennych wymagałoby też wcześniejszego ustandaryzowania.

Jako cel modelowania (zmienną targetową) można wybrać wilgotność gleby na średniej głębokości (czyli swvl3). Model mógłby wtedy opierać się na takich danych wejściowych, jak: wilgotność w pozostałych warstwach (płytkiej swvl1 lub swvl2 oraz głębokiej swvl4), temperatura powietrza, temperatura punktu rosy oraz opady. Takie modelowanie warto przeprowadzać oddzielnie dla poszczególnych klastrów (jest to uzasadnione wyraźnymi różnicami w ukształtowaniu terenu i klimacie poszczególnych stref).

6 Bibliografia

Literatura

- [1] Climate-Data.org, *Climate data for Cela, Portugal*. Dostęp online: <https://en.climate-data.org/europe/portugal/cela/cela-882347/> (dostęp: 2026).
- [2] Instituto Português do Mar e da Atmosfera (IPMA), *Atlas Climático Ibérico*. Lisboa, 2011. Dostęp online: https://www.ipma.pt/resources.www/docs_pontuais/ocorrencias/2011/atlas_clima_iberico.pdf
- [3] ERA5 hourly data on single levels from 1940 to present Dostęp online: <https://cds.climate.copernicus.eu/datasets/reanalysis-era5-single-levels?tab=overview>
- [4] ERA5 data documentation Dostęp online: <https://confluence.ecmwf.int/display/CKB/ERA5%3A+data+documentation>